

Text Analytics 2026 — Assignment 3

MLPs για Sentiment Classification (movie_reviews) και POS Tagging (UD English-EWT)

Φοιτητές: Νέγκι Χότζα (p3352524) · Γιώργος Κωστόπουλος (p3352520) · Αποστόλης Βελαόρας (p3352527)

Notebook: [Text Analytics Assignment3 GR FINAL.ipynb](#)

1. Σκοπός της εργασίας

Υλοποίηση και αξιολόγηση Multi-Layer Perceptron (MLP) μοντέλων σε PyTorch για δύο NLP εργασίες: (α) sentiment classification σε κριτικές ταινιών, και (β) Part-Of-Speech (POS) tagging σε αγγλικές προτάσεις.


Άσκηση 4: σύγκριση 3 αναπαραστάσεων (BoW, TF-IDF, Word2Vec centroids) × 5 αρχιτεκτονικών MLP, με 2 baselines (majority, logistic regression από Άσκηση 11/Εργασία 2) και 1 ensemble — συνολικά 18 αξιολογήσεις.

Άσκηση 5: window-based MLP POS tagger πάνω από pre-trained GloVe-100, 5 αρχιτεκτονικές + most-freq-tag baseline + 1 ensemble. Αξιολόγηση με per-class και macro Precision/Recall/F1/PR-AUC σε train/dev/test. Επιλογή best μοντέλου πάντα από dev (αποφυγή test leakage).

2. Δεδομένα και προεπεξεργασία

2.1 Άσκηση 4 — NLTK movie_reviews

NLTK movie_reviews (Pang & Lee 2004): 2.000 κριτικές (1.000 pos + 1.000 neg, balanced). Tokenized & lower-cased από το NLTK. Stratified split 70/15/15 (1.400 train / 300 dev / 300 test), σταθερό seed για αναπαραγωγιμότητα. Median μήκος ≈ 600 tokens.




Σχήμα 2.1 — Class balance και κατανομή μήκους κριτικών στο movie_reviews.

Τρεις αναπαραστάσεις χαρακτηριστικών:

- **BoW (5.000 features).** Raw counts των top-5.000 unigrams + bigrams.
- **TF-IDF (5.000 features).** L2-normalized, $\text{sublinear_tf} = 1 + \log(\text{tf})$. Το idf weighting υποβαθμίζει συχνές μη-διακριτικές λέξεις.
- **Word2Vec centroids (300 features).** Pretrained word2vec-google-news-300· document vector = μέσος όρος των word vectors της κριτικής.

2.2 Άσκηση 5 — UD English-EWT

Universal Dependencies English-EWT treebank, CoNLL-U format, official splits. Train: 12.544 προτάσεις / 204.578 tokens. Dev: 2.001 / 25.148. Test: 2.077 / 25.094. Tag set: 17 universal POS tags. Vocabulary 8.867 tokens (count ≥ 2 στο train ∩ GloVe). OOV → <UNK>· edges → <PAD>. Class imbalance: NOUN ≈ 17%, X ≈ 0.4%.



Σχήμα 2.2 — Κατανομή POS tags στο train. Heavy tail: 3 rare classes (X, INTJ, SYM) με < 1% support.

3. Υλοποίηση και μεθοδολογία

Μία κλάση CustomModel (PyTorch nn.Module) καλύπτει και τις 5 αρχιτεκτονικές μέσω flags: use_dropout, use_batchnorm, use_layernorm. Σειρά ανά hidden block: Linear → optional Norm → ReLU → optional Dropout. Όλες οι MLPs έχουν hidden = [256, 128] (2 hidden layers). Output layer: linear σε K logits, καμία ενεργοποίηση (η softmax εφαρμόζεται μέσα στο CrossEntropyLoss).

3.1 Πρωτόκολλο training

- **Loss:** Cross-entropy $\mathcal{L}(\theta) = -\log p_y(x)$. PyTorch χρησιμοποιεί log-sum-exp trick για αριθμητική σταθερότητα.
- **Optimizer:** Adam, $\eta=10^{-3}$, $\beta_1=0.9$, $\beta_2=0.999$. Weight decay (L2) = 10^{-5} .
- **Scheduler:** ReduceLROnPlateau (factor 0.5, patience 2) στο dev loss — υποδιπλασιάζει το lr σε plateaus.
- **Epochs:** 30 (Ex.4), 15 (Ex.5). Best-dev-loss checkpointing: επαναφορά weights της epoch με ελάχιστο dev loss — προστασία από overfitting.
- **Ensemble:** Temporal averaging (Izmailov 2018): $\theta^* = (1/K) \sum \theta^{(i)}$ από top-K best-dev checkpoints. K=5 (Ex.4), K=3 (Ex.5).

3.2 Hyperparameter tuning

Επιλογή best μοντέλου πάντα από dev macro-F1. Architecture sweep: 5 variants × 3 representations (Ex.4) = 15 runs · 5 variants × 1 GloVe (Ex.5) = 5 runs. Επιπλέον explicit grid search σε TF-IDF (Ex.4) με 9 cells: dropout ∈ {0.0, 0.3, 0.5} × hidden ∈ {[128], [256,128], [512,256]}. Best dev cell: hidden=[512,256] με dropout=0.3 → dev F1 = 0.833 (test 0.857)· όλες οι 9 cells εντός noise.

4. Μαθηματικά: Loss, Softmax, Back-propagation

4.1 Cross-Entropy Loss με Softmax

Για K κλάσεις, logits $\mathbf{o} \in \mathbb{R}^K$, σωστή κλάση y :

$$p_c = \text{softmax}(\mathbf{o})_c = e^{o_c} / \sum_j e^{o_j}$$

$$\mathcal{L}(\theta) = -\log p_y = -o_y + \log \sum_j e^{o_j}$$

4.2 Gradient του softmax+CE

Παραγωγίζοντας $\mathcal{L}$ ως προς το logit $\mathbf{o}_c$ (με αλυσίδα μέσω της softmax), προκύπτει η εξαιρετικά καθαρή κλειστή μορφή:

$$\partial \mathcal{L} / \partial \mathbf{o}_c = p_c - \mathbb{1}[c = y] \Rightarrow \mathbf{g}_o = \mathbf{p} - \mathbf{e}_y$$

Διαισθητικά: η σωστή κλάση λαμβάνει αρνητικό gradient ($p_y - 1 < 0 \Rightarrow$ ωθεί το logit ψηλότερα), οι λάθος κλάσεις θετικό p_c (ωθεί χαμηλότερα). Αριθμητικά σταθερό — δεν χρειάζεται να παραγωγίσουμε softmax και log χωριστά.

4.3 Back-propagation στο 2-hidden CustomModel

Forward pass με 2 hidden layers:

$$x \rightarrow z_1 = W_1 x + b_1 \rightarrow h_1 = \text{ReLU}(z_1) \rightarrow z_2 = W_2 h_1 + b_2 \rightarrow h_2 = \text{ReLU}(z_2) \rightarrow o = W_3 h_2 + b_3 \rightarrow \mathcal{L}$$

Backward pass (chain rule, από το loss προς τα weights):

$$\begin{aligned} g_o &= p - e_y \quad (\text{από softmax+CE}) \\ \partial \mathcal{L} / \partial W_3 &= g_o \cdot h_2^T, \quad \partial \mathcal{L} / \partial b_3 = g_o, \quad g_{\{h_2\}} = W_3^T g_o \\ g_{\{z_2\}} &= g_{\{h_2\}} \odot \mathbb{1}[z_2 > 0] \quad (\text{ReLU gradient}) \\ \partial \mathcal{L} / \partial W_2 &= g_{\{z_2\}} \cdot h_1^T, \quad g_{\{h_1\}} = W_2^T g_{\{z_2\}} \\ g_{\{z_1\}} &= g_{\{h_1\}} \odot \mathbb{1}[z_1 > 0], \quad \partial \mathcal{L} / \partial W_1 = g_{\{z_1\}} \cdot x^T \end{aligned}$$

4.4 Gradients ανά layer

- **Linear:** $z = Wh + b \Rightarrow \partial \mathcal{L} / \partial W = (\partial \mathcal{L} / \partial z) \cdot h^T$, $\partial \mathcal{L} / \partial h = W^T (\partial \mathcal{L} / \partial z)$ — αυτό συνεχίζει backwards.
- **ReLU:** $\partial \text{ReLU}(z) / \partial z = \mathbb{1}[z > 0]$. Σβήνει gradient όπου η pre-activation ήταν αρνητική (dead ReLU).
- **Dropout (training):** mask $m \sim \text{Bernoulli}(1-p)$ σταθερό μεταξύ forward και backward.
- **BatchNorm / LayerNorm:** $\hat{z} = (z - \mu) / \sqrt{\sigma^2 + \epsilon}$, $y = \gamma \hat{z} + \beta$. BN στατιστικά από batch (cross-batch εξάρτηση), LN από feature dim ανά παράδειγμα (independent από batch size).

4.5 Adam optimizer

$$\begin{aligned} m_t &= \beta_1 m_{t-1} + (1-\beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2 \\ \hat{m}_t &= m_t / (1-\beta_1^t), \quad \hat{v}_t = v_t / (1-\beta_2^t) \quad (\text{bias correction}) \\ \theta &\leftarrow \theta - \eta \cdot \hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon) \end{aligned}$$


5. Άσκηση 4 — Sentiment Classification

5.1 Baselines

- **Majority:** πάντα την πιο συχνή κλάση $\Rightarrow$ macro-F1 = 0.333 (balanced corpus).
- **Logistic Regression (Ex.11/Εργασία 2):** L2-regularised με $C \in \{0.1, 0.5, 1, 2, 5, 10\}$ tuned στο dev. Best $C=1.0 \rightarrow$ test macro-F1 = 0.837.

5.2 MLP sweep — 15 runs (5 architectures $\times$ 3 representations)

Επιλογή best από dev macro-F1. Από τους 15 winners, χτίζουμε temporal ensemble του dev-selected (avg-5 των top-5 best-dev checkpoints).




Σχήμα 5.1 — Loss curves για TF-IDF. MLP+LayerNorm overfit-άρει catastrophically (διπλή κανονικοποίηση: TF-IDF ήδη L2-normalized + LN).

5.3 Πλήρης πίνακας test results (18 μοντέλα)

Model	macro_P	macro_R	macro_F1	macro_AUC
majority (baseline)	0.250	0.500	0.333	0.500
logreg (Ex.11)	0.837	0.837	0.837	0.922
BoW · Linear	0.861	0.860	0.860	0.930
BoW · Plain MLP	0.818	0.817	0.816	0.883
BoW · MLP+Dropout	0.835	0.830	0.829	0.893
BoW · MLP+BatchNorm	0.794	0.793	0.793	0.908
BoW · MLP+LayerNorm	0.863	0.860	0.860	0.939
TFIDF · Linear	0.837	0.837	0.837	0.916
TFIDF · Plain MLP	0.867	0.867	0.867	0.937
TFIDF · MLP+Dropout	0.844	0.843	0.843	0.934
TFIDF · MLP+BatchNorm	0.863	0.863	0.863	0.940
TFIDF · MLP+LayerNorm	0.808	0.763	0.754	0.904
W2V · Linear	0.678	0.677	0.676	0.750
W2V · Plain MLP	0.832	0.830	0.830	0.899
W2V · MLP+Dropout	0.795	0.793	0.793	0.887
W2V · MLP+BatchNorm	0.828	0.820	0.819	0.910
W2V · MLP+LayerNorm	0.800	0.800	0.800	0.888
TFIDF·MLP+Dropout (avg-5) ★	0.854	0.853	0.853	0.941

Πίνακας 5.1 — Test macro metrics. Bold: TFIDF · Plain MLP (test winner, F1=0.867) και ★ TFIDF · MLP+Dropout (avg-5) ensemble (dev-selected, υψηλότερο PR-AUC=0.941).



Σχήμα 5.2 — Test macro-F1 bar chart. TF-IDF οικογένεια (πλην LayerNorm) κυριαρχεί· W2V centroids υπό-αποδίδουν λόγω averaging.

6. Άσκηση 5 — POS Tagging


6.1 Window features + WindowTagger

Για κάθε token c_t της πρότασης, window radius $r=2$: $x_t = [c_{t-2}, c_{t-1}, c_t, c_{t+1}, c_{t+2}]$, $|window|=5$. Edges padded με $\langle PAD \rangle$. OOV $\rightarrow \langle UNK \rangle$. Pipeline: Embedding ($V \times 100$, padding_idx=0) $\rightarrow$ flatten (500-dim) $\rightarrow$ CustomModel(hidden=[256,128]) $\rightarrow$ 17-way logits.

Pretrained GloVe-100 (glove-wiki-gigaword-100, 400.000 λέξεις, 100d) μέσω gensim. Embedding matrix initialised από GloVe για 8.867 tokens, trainable κατά το POS training.

6.2 Most-frequent-tag baseline

$\text{tag}^*(w) = \text{argmax}_t \text{count}(w_i=w \wedge y_i=t)$ στο train. OOV $\rightarrow$ fallback most-freq overall (NOUN). Test macro-F1 = 0.787 — strong baseline επειδή πολλές λέξεις έχουν μία κυρίαρχη POS.



Σχήμα 6.1 — Combined dev loss των 5 POS αρχιτεκτονικών.

6.3 Test set — όλα τα μοντέλα


Model	macro_P	macro_R	macro_F1	macro_AUC
most-freq tag (baseline)	0.820	0.776	0.787	0.686
Linear ★ dev-selected	0.872	0.851	0.861	0.900
Plain MLP	0.871	0.837	0.851	0.896
MLP+Dropout	0.869	0.846	0.856	0.895
MLP+BatchNorm	0.868	0.843	0.854	0.899
MLP+LayerNorm (test winner)	0.874	0.857	0.864	0.900
Linear (avg-3)	0.864	0.851	0.856	0.900

Πίνακας 6.1 — Test macro metrics. MLP+LayerNorm test winner (0.864) · Linear dev-selected (0.861, AUC 0.900).

6.4 Per-tag F1 του Linear (test)

Tag	F1	Tag	F1	Tag	F1
ADJ	0.88	DET	0.99	NUM	0.82
ADP	0.95	INTJ	0.88	PART	0.97
ADV	0.90	NOUN	0.88	PRON	0.98
AUX	0.98	PROPN	0.78	PUNCT	0.99
CCONJ	0.99	SCONJ	0.84	SYM	0.87
VERB	0.93	X	0.00	macro	0.861

Πίνακας 6.2 — Per-tag F1 (17 UPOS). High performers: PUNCT, DET, CCONJ, AUX, PRON, PART ≥ 0.97 . Δύσκολες: X=0.00 (rare, 0.4% support), PROPN=0.78, NUM=0.82.



Σχήμα 6.2 — Normalized confusion matrix (test, Linear). Διαγώνιος > 0.85· κύρια σύγχυση AUX↔VERB, ADJ↔NOUN.

7. Σχολιασμός αποτελεσμάτων

7.1 Άσκηση 4 — Sentiment

- TF-IDF > BoW σε όλες τις αρχιτεκτονικές πλην LayerNorm. Το L2 normalization + sublinear-tf σταθεροποιεί τις κλίμακες και αναβαθμίζει σπάνιους discriminative όρους μέσω idf. Test winner: TFIDF · Plain MLP F1=0.867.
- TFIDF · MLP+LayerNorm — αποτυχία (test F1=0.754). Το TF-IDF είναι ήδη L2-normalized, οπότε LayerNorm επιχειρεί διπλή κανονικοποίηση που οδηγεί σε αστάθεια. Παρατηρούμε καθαρό overfit (train F1=0.909, dev loss > 0.85).
- BoW · MLP+LayerNorm είναι παράδοξα από τα καλύτερα BoW (F1=0.860): στο μη-κανονικοποιημένο BoW το LayerNorm προσφέρει την κανονικοποίηση που λείπει. Αντίστροφο μοτίβο σε σχέση με το TF-IDF — η σωστή normalization πρέπει να ταιριάζει στο feature space.
- W2V centroids υπό-αποδίδουν (best 0.830 vs TF-IDF 0.867). Το averaging εκατοντάδων vectors χάνει sentiment-discriminative πληροφορία: negation ("not good"), intensifiers, polarity-flipping bigrams σβήνουν στον μέσο όρο. $\cos(c_{pos}, c_{neg}) = 0.998$ — αριθμητική απόδειξη.
- MLP κερδίζει logreg μόνο +0.03 macro-F1 $\Rightarrow$ το πρόβλημα είναι σχεδόν γραμμικά διαχωρίσιμο στο TF-IDF space. Πραγματική νίκη: ensemble (avg-5 του Dropout) με PR-AUC = 0.941 vs logreg 0.922.

7.2 Άσκηση 5 — POS Tagging

- Όλα τα MLPs ξεπερνούν το most-freq-tag baseline κατά +6 έως +8 macro-F1 points. Το context window επιτρέπει αποσαφήνιση ambiguous λέξεων ("book" NOUN vs VERB, "can" AUX vs NOUN).
- MLP+LayerNorm test winner (F1=0.864) αλλά Linear dev-selected (F1=0.861). Η dev/test διαφορά εντός run-to-run noise ($\sim \pm 0.005$). Σωστή πρακτική (dev selection) — defensible παρά τη μικρή υπεροχή LayerNorm στο test.

- Linear (0 hidden layers) νικά το dev κόντρα σε 4 αρχιτεκτονικές με 2 hidden layers η καθεμία. Τα GloVe embeddings ήδη κωδικοποιούν τις POS-discriminative ιδιότητες — η non-linearity προσφέρει αμελητέο πλεονέκτημα.
- LayerNorm εδώ λειτουργεί καλά, αντίθετα με Ex.4. Με dense GloVe inputs (500d concat), per-example normalization βοηθάει· στο sparse TF-IDF (5000d, mostly zeros) προκάλεσε αστάθεια.
- Rare class "X" (0.4% support): F1=0 για 6/7 μοντέλα, F1=0.17 μόνο LayerNorm. Train-test gap $\approx$ 10pts αλλά dev (0.852) $\approx$ test (0.861) — best-dev checkpointing απομονώνει βέλτιστη epoch χωρίς dev-leakage.

8. Συμπεράσματα

- Δεν υπάρχει universal winner για architecture normalization. LayerNorm είναι catastrophic σε TF-IDF (διπλή normalization) αλλά καλό σε POS με GloVe embeddings. BatchNorm το πιο σταθερό.
- Pretrained embeddings κατάλληλα για windowed POS tagging· όχι ως sentence representations για sentiment (averaging χάνει πληροφορία).
- Dev-selected $\neq$ test winner λόγω μικρού dev set, αλλά εντός noise. Επιλογή από dev παραμένει σωστή πρακτική (αλλιώς test leakage).
- Όταν inputs είναι ήδη πλούσια (GloVe), Linear classifier είναι ανταγωνιστικός με deep MLPs — βάθος δεν είναι πάντα η απάντηση.

Final scoreboard

Task	Best (dev-selected)	macro_F1	PR-AUC	Baseline F1
Άσκηση 4 (sentiment)	TFIDF · MLP+Dropout (avg-5)	0.853	0.941	0.837 (logreg)
Άσκηση 5 (POS tagging)	Linear ★ dev-selected	0.861	0.900	0.787 (most-freq)

9. Συνεισφορά ομάδας

Η εργασία πραγματοποιήθηκε συνεργατικά και ισάξια από τους τρεις φοιτητές (Νέγκι Χότζα, Γιώργος Κωστόπουλος, Αποστόλης Βελαόρας). Όλοι συμμετείχαμε σε όλα τα στάδια: φόρτωση/προεπεξεργασία δεδομένων, σχεδιασμό και υλοποίηση MLP αρχιτεκτονικών σε PyTorch, εκπαίδευση και hyperparameter tuning στο dev, αξιολόγηση με per-class/macro metrics, οπτικοποίηση (loss curves, bar charts, confusion matrix), μαθηματικές παραγωγές (back-propagation, softmax+CE gradient, Adam), ερμηνεία αποτελεσμάτων (§7) και συγγραφή του report.